

1. 本研究の概要: Full-Duplex アーキテクチャを採用した音声対話システムは雑音によって性能低下を起こすのかを調査

音声対話システムのアーキテクチャ

カスケードアーキテクチャ (例: Freeze-Omni^[1])

■ モジュールを直列に接続して処理

Full-Duplex アーキテクチャ (例: Moshi^[2], PersonaPlex^[3])

■ ユーザ・システム音声ストリームを並列・同時に処理

従来: clean 環境での評価

処理対象の音声以外の音が無い clean 環境での音声対話システムの性能評価

本研究: 雑音環境での評価

実環境に近い様々な雑音環境での性能評価

2. 実験方法: Full-Duplex-Bench^[4] がベース → モデルへの入力音声に DEMAND^[5] の雑音を加算

Full-Duplex-Bench

雑音を加算^{※1}
DEMAND (18種類)

※1: 入力音声の Active Speech Level^[6] と雑音の RMS で SNR を計算

タスク名	Pause Handling	ユーザのターンで黙ってられるか
	Backchanneling	相槌を入れることができるか
	Smooth Turn Taking	スムーズにターンテイクできるか
	User Interruption	ユーザの割り込みみに適切に反応できるか

評価指標定義

■ Take Over Rate (TOR): モデルがターンテイクした割合

$$TOR = \frac{1}{N} \sum_{i=1}^N TO_i \quad TO_i = \begin{cases} 1 & (2語以上または1秒以上) \\ 0 & otherwise \end{cases}$$

■ Latency: モデルの応答遅延 [秒]

$$Latency = (\text{モデルの発話開始時刻}) - (\text{入力音声の発話終了時刻})$$

■ GPT-4o Score: モデルの応答内容を GPT-4o が評価 (0~5の6段階)

↳ User Interruptionのみ対象

※各タスクで各指標を計測したが、評価指標の穴を発見 (下記「評価指標の限界」参照)

→ 「3. 実験結果」では GPT-4o Score のみ分析対象

3. 実験結果: 雑音のパワーが音声帯域に集中するほど GPT-4o Score の低下を招く & 評価指標の限界が見えた

