

1. 本研究の概要: Full-Duplex アーキテクチャを採用した音声対話システムは雑音によって性能低下を起こすのかを調査

音声対話システムのアーキテクチャ

カスケードアーキテクチャ (例: Freeze-Omni^[1])

■ モジュールを直列に接続して処理

Full-Duplexアーキテクチャ (例: Moshi^[2], PersonaPlex^[3])

■ ユーザ・システム音声ストリームを並列・同時に処理

従来: clean環境での評価

処理対象の音声以外の音が無い clean 環境での音声対話システムの性能評価

本研究: 雑音環境での評価

実環境に近い様々な雑音環境での性能評価

2. 実験方法: Full-Duplex-Bench^[4]がベース → モデルへの入力音声にDEMAND^[5]の雑音を加算

Full-Duplex-Bench

雑音を加算^{※1}
DEMAND (18種類)

※1: 入力音声のActive Speech Level^[6]と雑音のRMSでSNRを計算

タスク名	Pause Handling	ユーザのターンで黙ってられるか
	Backchanneling	相槌を入れることができるか
	Smooth Turn Taking	スムーズにターンテイクできるか
	User Interruption	ユーザの割り込みに適切に反応できるか

評価指標定義

■ Take Over Rate (TOR): モデルがターンテイクした割合

$$TOR = \frac{1}{N} \sum_{i=1}^N TO_i \quad TO_i = \begin{cases} 1 & (2語以上または1秒以上) \\ 0 & otherwise \end{cases}$$

■ Latency: モデルの応答遅延 [秒]

$$Latency = (\text{モデルの発話開始時刻}) - (\text{入力音声の発話終了時刻})$$

■ GPT-4o Score: モデルの応答内容を GPT-4o が評価 (0~5の6段階)

↳ User Interruptionのみ対象

※各タスクで各指標を計測したが、評価指標の穴を発見 (下記「評価指標の限界」参照)

→ 「3. 実験結果」では GPT-4o Score のみ分析対象

3. 実験結果: 雑音の帯域が人間の音声に近いほど GPT-4o Score の低下をまねく & 評価指標の限界が見えた

雑音の帯域の影響

図1: SNR と GPT-4o Score ↑

(図1) 👉 雑音が大きくなると **GPT-4o Score 低下**

(図2) 👉 雑音ごとに悪化量のばらつき大

(図3) 👉 雑音全体のパワーに占める **音声に近い帯域のパワーの割合**が GPT-4o Score 悪化量に強い**相関**

図2: 雑音種類別 GPT-4o Score の悪化量 (濃いほど悪化)

図3: 雑音に含まれる狭帯域電話帯域^[7]の割合と悪化量の相関

注釈:
(1) GPT-4oスコア悪化量は0 dBでの結果
(2) 帯域について
下 100 ~ 500 Hz
上 2 ~ 8 kHz まで
広げても
p=0.86 ~ 0.96
(3) 下限を50 Hz まで
下げると相関係数が
p = 0.70 まで低下

評価指標の限界

👉 Full-Duplex-Benchに**判定の穴**が存在

Full-Duplex-Bench は
Full-Duplex モデル特有の会話ダイナミクスの客観評価指標を提案
モデルの挙動を正しく反映できていないケースが存在 → **判定の穴**

例1: TOR

Turn Taking が1箇所でもあった、その**出力音声全体で TO = 1**
Backchanneling や Pause Handling はTO = 0 のサンプルのみを対象とするため**実態と乖離**

例2: Latency

実際は Latency = **0.060 秒**ほど
Full-Duplex-Bench では Latency = **0.240 秒**
アノテーションの質や**ASR・VADの性能**に大きく依存

例3: GPT-4o Score

GPT-4o Score の評価対象が不適切 & **判定対象の区別**が難しい

今後の展望

主観評価の実施による客観評価指標の妥当性検証: 客観指標は主観と一致するか?

客観評価指標の改良: 主観と一致する検出を可能にするにはどうしたらよいか?

残響の影響を調査: SNRや雑音帯域と比べて残響の影響はどうか?

雑音頑健性の向上手段を検討: どうすればモデルが雑音に頑健になるか?

参考文献

[1] X. Wang et al., Proc. ICML, 2025.
[2] A. Défossez et al., arXiv:2410.00037, 2024.
[3] R. Roy et al., Proc. ICASSP, 2026.
[4] G.-T. Lin et al., Proc. ASRU, 2025.
[5] J. Thieme et al., Proc. Meetings on Acoustics, 2013.
[6] ITU-T Rec. P.56, 2011.
[7] ITU-T Rec. G.712, 2001.

謝辞

本研究は、JST, Moonshot R&D 助成金番号JPMJPS2011 と、JSPS 科研費 26H02531 による支援を受け実施した。